

코드잇 스프린트 DA과정 중급2 프로젝트



무료체험 고객 행동 기반 유료 전환 분석 및 마케팅 전략 제안



이현재 김영선 원정서 유주연 전서은 정예서 황희선

7팀

2026.06



목차

- 1 문제의식 및 분석 목표
- 2 데이터 구성 및 전처리 기준
- 3 EDA: 결제 전환과 행동 변수의 관계
- 4 모델링 분석: 결제 가능 고객 선별
- 5 모델 해석 및 핵심 변수
- 6 시공간분석 및 통계검정
- 7 클러스터링 분석: 고객 유형 분류
- 8 고객 유형별 마케팅 전략 제안
- 9 분석 한계 및 향후 개선 방향
- 10 QnA

문제의식 및 분석 목표



문제의식




무료체험 신청자가
모두 유료 결제로 이어지지 않는다



단순 방문 여부나 이용량 만으로는
결제 전환을 충분히 설명하기 어렵다



따라서 고객의 방문 패턴과 행동 특성을
기준으로 전환 가능성이 높은 고객군을
파악할 필요가 있다



분석목표



무료체험 고객의 행동 데이터 기반
유료 결제 전환과 관련 있는 요인 분석



방문시간대/이용량/반복 방문/
패턴에 따라 고객 유형화



머신러닝 모델을 활용해
결제 가능성이 높은 고객군 선별



분석 결과를 바탕으로
고객 유형별 마케팅 전략 제안

데이터 구성 및 전처리 기준

데이터 구성



- 무료체험 신청 데이터
- 방문 및 체류 정보 데이터
- 출입 로그 데이터
- 유료 결제 여부 데이터
- 지점 면적 데이터

분석단위



- 사용자 1명 기준 데이터 통합
- 신청/방문/출입/결제 데이터를 USER_UUID 기준으로 결합
- 최종적으로 고객별 행동 특성
- 요약한 분석 테이블 생성

주요 전처리 기준



- 날짜/시간 컬럼 datetime 변환
- 결측치 및 중복 데이터 제거
- 재신청 유저 제거
- 실제 첫방문/첫 출입 기준으로
- 3일 무료체험 기간 정의
- 체험 범위를 벗어난 기록 제거
- 비정상 체류시간 데이터 정제



Raw Data



User-level Table



Analysis Dataset


EDA: 결제 전환과 행동 변수의 관계

반복 방문 여부와 방문 시간대에 따라 결제율의 차이가 나타난다.

핵심 지표

1일 방문 고객 결제율	2일 이상 재방문 고객 결제율	결제율 차이
32.93%	41.95%	+9.02%p (재방문 고객 기준)

방문일수별 결제율 비교



반복 방문 고객의 결제율이 더 높다

EDA 결론

단순 이용량보다 반복 방문과 방문 패턴이 결제 전환 해석에 더 중요

5페이지

※ 분석 대상: 최종 분석 데이터셋 8,908명 / 유료 전환 3,303명, 미전환 5,605명

모델링(전체 유저)

결제 전환 예측 모델링

3일 무료 체험 신청자 전체를 대상으로 결제 가능성이 높은 고객을 선별

전체 신청자

8,908명

사용자당 1명 = 1행
(전체 고객 기준 모델링)

결제자

3,303명

타겟 클래스
(결제 전환율 예측)

전체 결제율

37.08%


불균형 고려 필요
(마케팅 타겟 우선 순위)

분석 대상 정의

방문 정보 기준으로 방문자, 미방문자 구분

구분	고객수	결제자수	결제율
전체 신청자	8908	3303	37.08%
방문자	5493	2052	37.36%
미방문자	3415	1251	36.63%

미방문자 중에서도 1,251명이 결제했기 때문에, 방문자만 분석하면 실제 결제 전환 고객의 약 38%를 제외하게 된다. 따라서 결제 전환을 전체 고객 관점에서 설명하기 위해 전체 신청자 기준으로 모델링을 진행하였다.



변수 설계 및 정제 기준

결측, 중복, 다중공선성을 제거해 모델링이 가능한 변수 설정

후보 변수

22개

초기 후보

VIF 기준

5.0 미만

최종 수치형 변수 6개

고상관 위험 변수

원핫 인코딩 이후 정제

최종 범주형 변수 7개

변수 정제 목적:

성능을 억지로 높이기보다, 해석 가능하고
안정적인 결제 전환 예측 모델

수치형

- 1.첫이용까지걸린기간
- 2.방문일수
- 3.방문일당체류시간
- 4.방문일당출입로그수
- 5.업무시간출입비율
- 6.입퇴실횟수차이

범주형


- 1.24시간내이용여부
- 2.2일이상이용여부
- 3.3일모두이용여부
- 4.지점면적결측여부
- 5.신청월
- 6.신청요일
- 7.신청분기

변수가 많거나 서로 겹치면 모델 해석이 불안정해질 수 있다.
따라서 VIF와 고상관 변수 제거를 통해 과적합 위험을 줄이고,
해석 가능한 모델링 변수를 구성하였다.

모델 후보 비교

Train 내부 교차 검증 ROC-AUC 기준으로 최종 모델 선택

후보 모델 5개 비교



최종 선택

Logistic_Regression_Balanced

 **ROC_AUC 1위**

 **F1-SCORE 1위**

전체 고객 중 결제 가능성이 높은 고객을 안정적으로 선별하기 위해 Train 내부 교차검증 ROC-AUC 1위 모델을 최종 선택하였다.

최종 모델 Test 성능

Threshold 0.36 : 결제 가능 고객을 넓게 포착하는 RECALL 중심 모델

분류기준값	정밀도	재현율	F1점수
0.42	0.4022	0.8865	0.5534
0.40	0.3967	0.9153	0.5535
0.38	0.3927	0.9380	0.5536
 0.36	0.3903	0.9637	0.5556

최종 선택

임계값 : 0.36




RECALL 1위



F1-SCORE 1위

Test set에서 여러개 Threshold를 적용해 비교한 뒤
Threshold 0.36을 적용한 결과 Recall과 F1-score가 가장 높아
결제 가능 고객을 넓게 포착하는 기준으로 채택하였다.

최종 모델 Test 성능



고재현율 타깃 선별형

성능이 강한 모델은 아니지만, 결제 가능 고객을 놓치지 않고 놓치지 않고 넓게 잡는 타깃 선별용 모델

성능이 매우 강한 모델은 아니지만, 재현율(Recall) 0.9637로 실제 결제 고객을 대부분 포착하였다.

반면 오탐(False Positive)이 많아 정밀한 예측에는 한계가 있으므로, 이 모델은 '정확한 판별용'보다 결제 가능 고객을 넓게 선별하는 1차 타겟팅 모델로 해석한다.

Top- k LIFT: 타킷 선별 효과


모델 상위 고객군의 실제 결제율이 전체 평균보다 높은지 확인

상위 그룹	대상 고객수	실제 결제 고객수	그룹 결제율(%)	전체 결제율(%)	Lift
상위 10%	178	104	58.43	37.09	1.5751
상위 20%	356	208	58.43	37.09	1.5751
상위 30%	534	268	50.19	37.09	1.3530
상위 50%	891	396	44.44	37.09	1.1982

모델 상위 10~20% 고객군의 결제율은 약 58.43%로, 전체 평균 37.09%보다 높았다. 따라서 모델을 활용하면 결제 가능성이 높은 고객을 우선 선별할 수 있다.

변수 중요도 Top 5

Permutation Importance : 결제 전환과 가장 연결된 행동 신호



- 첫 이용까지 걸린기간이 길수록 전환 신호
- 2일 이상 사용 여부가 핵심 행동지표
- 체류 시간은 단순 방문보다 강한 사용 의도 신호

- 변수중요도 상위 변수는 대부분 '신청 후 얼마나 반복적으로, 얼마나 오래 이용했는가'에 집중되어 있다.
- 따라서 결제 전환은 단순 방문 여부보다 실제 이용 의지와 사용 강도를 보여주는 행동 신호와 더 밀접하게 연결된 것으로 해석된다.

전체 고객 결론

예측력 약함

ROC-AUC 0.6106 Top 10% LIFT 1.5751
정확한 예측보다는 우선관리 고객 선별이 목적

핵심 변수

첫 이용까지 걸린 기간, 2일 이상 방문여부
평균 체류시간, 신청월

결론

빠르게 방문하고 반복 이용한 고객일수록 전환 신호 ↑
전체 모델 -> 1차 타깃 선별 / 방문자 모델 → 행동 패턴 해석


미방문자도 결제자가 1,251명 존재하므로 전체 고객을 제외하면 실제 전환 고객이 누락될 수 있다.

다만 방문 행동 정보가 없는 고객이 포함되어 예측력은 제한적이므로, 전체대상 모델은 정확한 예측보다 우선관리 타깃 선별용으로 해석하였다.

방문자 결제 예측 모델링

1차 모델링 - 8개 피처 로지스틱 회귀 - AUC 0.6272

로지스틱 회귀(8개)



*혼동행렬(좌) · 회귀 계수(우) — 빨강 = 결제↑, 파랑 = 결제↓. visit_days·days_to_first_visit가 양(+), avg_stay_sec이 음(-).

ROC-AUC **0.6272**

지표	미결제	결제	전체
Precision	0.71	0.45	—
Recall	0.56	0.61	—
F1-score	0.63	0.52	—
Accuracy	—	—	0.58
ROC-AUC	—	—	0.6272


미결제 Precision(0.71)이 결제(0.45)보다 높은 반면, Recall은 결제(0.61)가 더 높음.
class_weight='balanced' 적용으로 소수 클래스인 결제 집단을 놓치지 않는 방향으로 학습된 결과임.

- 체험 사용자의 결제 전환 요인을 분석하기 위해 EDA기준 유의미한 8개의 변수로 로지스틱 회귀분석을 수행하였다.
- 분석 결과 모델의 ROC-AUC는 0.6272로 나타났으며, 방문일수와 첫 방문까지의 소요기간은 결제 확률에 정(+)의 영향을, 평균 체류시간은 부(-)의 영향을 미치는 것으로 확인되었다.

1차 모델링 - 8개 피처 랜덤포레스트

- AUC 0.6020

랜덤포레스트 (8개)



ROC-AUC

0.6020


지표	미결제	결제	전체
Precision	0.66	0.47	—
Recall	0.79	0.31	—
F1-score	0.72	0.37	—
Accuracy	—	—	0.61
ROC-AUC	—	—	0.602

- 로지스틱 회귀와 랜덤포레스트를 활용하여 결제 전환 예측 성능을 비교한 결과, 로지스틱 회귀는 ROC-AUC 0.6272, 랜덤포레스트는 ROC-AUC 0.6020으로 나타났다.
- 랜덤포레스트는 미결제 고객 탐지 성능(Recall=0.79)이 높았으나 결제 고객 탐지 성능(Recall=0.31)은 상대적으로 낮게 나타났으며, 전반적으로는 로지스틱 회귀가 결제 전환 예측에 더 적합한 모델로 판단되었다.

1차 모델링 - 8개 피처 Light GBM

- AUC 0.6200

Light GBM (8개)




ROC-AUC **0.6200**

지표	미결제	결제	전체
Precision	0.69	0.46	—
Recall	0.63	0.52	—
F1-score	0.66	0.48	—
Accuracy	—	—	0.59
ROC-AUC	—	—	0.6200

- LightGBM은 미결제와 결제 고객을 균형 있게 탐지(Recall 각각 0.63, 0.52)해내며 랜덤포레스트보다 우수한 0.6200의 ROC-AUC 성능을 보였으나, 전반적인 예측력은 여전히 로지스틱 회귀가 가장 앞서는 것으로 나타났다.
- 결과적으로 복잡한 머신러닝 알고리즘보다 데이터의 명확한 선형 경향성을 포착하고 분석 결과의 직관적인 해석이 가능한 로지스틱 회귀가 최종 모델로 가장 적합하다고 판단되었다.

2차 모델링 - 6개 피처 로지스틱 회귀 - AUC 0.6252


로지스틱 회귀(6개)

ROC-AUC **0.6252**

지표	미결제	결제	전체
Precision	0.7	0.45	—
Recall	0.56	0.59	—
F1-score	0.62	0.51	—
Accuracy	—	—	0.57
ROC-AUC	—	—	0.6252

- 다중공선성 검토 결과 VIF가 10 이상인 변수를 제외하고 6개 변수만을 활용하여 로지스틱 회귀분석을 재수행하였다.
- 정확도는 57%, ROC-AUC는 0.6252로 나타났으며, 기존 8개 변수 모델(ROC-AUC=0.6272)과 유사한 성능을 유지하였다. 이는 다중공선성이 높은 변수를 제거하더라도 모델의 예측력이 크게 감소하지 않았음을 의미하며, 보다 안정적이고 해석 가능한 모형을 구축할 수 있음을 시사한다.

2차 모델링 - 6개 피처 랜덤포레스트 - AUC 0.5672

ROC-AUC **0.5672**


지표	미결제	결제	전체
Precision	0.65	0.43	—
Recall	0.74	0.32	—
F1-score	0.69	0.37	—
Accuracy	—	—	0.58
ROC-AUC	—	—	0.5672

- 동일한 6개 변수를 기반으로 머신러닝 알고리즘인 랜덤포레스트와 LightGBM을 활용해 성능을 비교 분석하였다.
- 랜덤포레스트 분석 결과, ROC-AUC는 0.5672로 나타났으며 미결제 고객 탐지 성능(Recall=0.74)에 비해 실제 결제 고객을 맞추는 성능(Recall=0.32)이 크게 떨어져 전반적인 판별력이 가장 낮게 측정되었다.

2차 모델링 - 6개 피처 Light GBM

- AUC 0.6132

ROC-AUC **0.6132**




지표	미결제	결제	전체
Precision	0.69	0.46	—
Recall	0.62	0.53	—
F1-score	0.49	0.37	—
Accuracy	—	—	0.59
ROC-AUC	—	—	0.6132

- LightGBM 분석 결과는 ROC-AUC 0.6132로 랜덤포레스트 대비 우수한 예측력을 보였다.
- 미결제 고객(Recall=0.62)과 결제 고객(Recall=0.53)을 비교적 균형 있게 탐지해내는 경향을 확인할 수 있었다.
- 결과적으로, 로지스틱 회귀가 변수 정제 후에도 여전히 가장 적합한 모델임을 재확인하였다.

3차 모델링 - 3개 피처 로지스틱 회귀 - AUC 0.6267

로지스틱 회귀(3개)


ROC-AUC **0.6267**

지표	미결제	결제	전체
Precision	0.7	0.45	—
Recall	0.56	0.6	—
F1-score	0.63	0.52	—
Accuracy	—	—	0.58
ROC-AUC	—	—	0.6267

- 변수 중요도와 다중공선성 검토 결과를 바탕으로 설명력이 높은 3개 변수만을 활용하여 로지스틱 회귀분석을 수행하였다.
- 분석 결과 ROC-AUC는 0.6267로 나타났으며, 기존 8개 변수 모델(0.6272) 및 6개 변수 모델(0.6252)과 거의 동일한 수준의 예측 성능을 보였다. 이는 핵심 변수만으로도 결제 전환을 상당 부분 설명할 수 있음을 의미하며, 변수 수를 줄임으로써 모델의 단순성과 해석 가능성을 높일 수 있다.

3차 모델링 - 3개 피처 랜덤포레스트 - AUC 0.5428

랜덤 포레스트 | 피처 3개 | AUC 0.5428

ROC-AUC **0.5428**


지표	미결제	결제	전체
Precision	0.64	0.40	—
Recall	0.64	0.41	—
F1-score	0.64	0.40	—
Accuracy	—	—	0.55
ROC-AUC	—	—	0.5428

- 랜덤포레스트 분석 결과, ROC-AUC는 0.5428로 나타났다.
- 피처가 3개로 축소되면서 과적합 완화나 복잡한 트리 구조의 장점을 살리지 못해, 전체 비교 모델 중 가장 낮은 판별력과 예측 성능을 기록하였다.

3차 모델링 - 3개 피쳐 Light GBM

- AUC 0.6033

LightGBM | 피쳐 3개 | AUC 0.6033



ROC-AUC

0.6033

지표	미결제	결제	전체
Precision	0.69	0.45	—
Recall	0.61	0.54	—
F1-score	0.65	0.49	—
Accuracy	—	—	0.60
ROC-AUC	—	—	0.6033


- LightGBM 분석 결과는 ROC-AUC 0.6033으로, 변수의 수가 대폭 줄어들었음에도 불구하고 랜덤포레스트 대비 안정적인 성능을 유지하였다.
- 종합적으로 핵심 변수 3개만을 활용한 모델링에서도 로지스틱 회귀가 가장 높은 ROC-AUC(0.6267)로 적합한 모델임을 재확인하였다.

3차 모델링 - 3개 피처 베이지안 로지스틱 회귀

- AUC 0.6264


- 베이지안 로지스틱 회귀 결과, 방문일수와 첫 방문까지의 소요기간은 결제 확률을 높이는 요인으로 나타났으며, 평균 체류시간은 결제 확률을 낮추는 요인으로 확인되었다.
- 모든 변수의 신뢰구간이 0을 포함하지 않았고 R-hat 값이 1에 근접하여 모형의 수렴성과 추정 안정성이 확보된 것으로 판단된다.

베이지안 로지스틱 회귀계수 사후 분포



피처	사후 평균	표준편차	89% CI 하한	89% CI 상한	R-hat
방문일수 (betas[0])	0.3482	0.0339	0.2939	0.4029	1.0001
평균방문 시간 (betas[1])	-0.3363	0.0349	-0.3927	-0.2806	1.0002
첫 방문까지 걸린 일수 (betas[2])	0.2434	0.0341	0.1896	0.2986	0.9998
intercept	-0.545	0.0328	-0.5966	-0.4926	1.0009

3차 모델링 - 3개 변수별 결제 전환율



- 방문일수가 증가할수록 전환율은 33.0%에서 44.0%까지 상승하는 경향을 보였다.
- 첫 방문까지 걸린 기간이 길수록 전환율 역시 28.7%에서 43.8%까지 증가하였다.
- 반면 평균 체류시간은 길어질수록 전환율이 감소하여, 4시간 이상 이용 고객의 전환율은 32.1%로 나타났다.
- 결제 전환이 단순히 오래 이용하는 것보다 반복 방문과 계획적인 이용 행동에 더 크게 영향을 받음을 의미한다.

행동 패턴 분석을 통한 결제 전환율 분석

— 행동 패턴 분석을 통한 결제 전환율 분석

- 3일 무료체험 신청자를 대상으로 행동 패턴에 따른 고객 유형을 분류하고 결제 전환율을 비교

행동변수 선정 및 추가 전처리

분석 대상

무료체험 신청자 8,908명
미방문자(3,415명/ 38.3%) 포함
평균 결제율 37.1%

변수 선정

총 방문 일수
평균 체류 시간
신청 후 시작까지 걸린 일수

추가 전처리


총 방문 일수/ 평균 체류시간 → 0으로 대체
체험 시작까지 걸린 일수 → -1로 대체

행동 패턴 분석을 통한 결제 전환율 분석

K의 개수 구하기 | Elbow Method

K=3이후
inertia 감소폭 완만

Elbow Method For Optimal K



행동 패턴 분석을 통한 결제 전환율 분석


K-Means 클러스터링 | 페르소나 정의

user_cluster (8,908명)	방문 일수	평균 체류	체험 대기	실제 결제율
cluster 0 (2,763개)	2.17일	5.88시간	0.84일	35.3%
cluster 1 (3,334개)	0.02일	0.01시간	-	36.3%
cluster 2 (2,811개)	1.14일	2.70시간	1.41일	40.0%

cluster 2의 체험 대기

→ cluster1은 3,334명 중 3,280명(98.4%)이 미방문자로 구성된 군집으로,
체험 시작 기록이 없어 체험 대기 일수를 산출할 수 없다.

군집별 결제/ 미결제 비율



행동 패턴 분석을 통한 결제 전환율 분석

K-Means 클러스터링 | 페르소나 정의

user_cluster (8,908명)	방문 일수	평균 체류	체험 대기	실제 결제율
cluster 0 (2,763개)	2.17일	5.88시간	0.84일	35.3%
cluster 1 (3,334개)	0.02일	0.01시간	-	36.2%
cluster 2 (2,811개)	1.14일	2.70시간	1.41일	40.0%

- **cluster 0 : 고관여 유저**
방문일수 2.17일, 평균 체류 5.88시간으로 전체 군집 중 압도적 1위이다.
서비스 내의 콘텐츠를 깊숙하게 탐색하고 검토하는 고관여 집단이다.
- **cluster 1 : 미방문 결제 유저**
지표가 거의 0에 수렴한다.
신청만 해두고 서비스 자체를 거의 이용하지 않는 유저들이다.
- **cluster 2 : 목적 지향형 결제 유저**
방문일수 1.14일, 평균 체류 2.70시간으로 cluster 0에 비해 절반 수준이지만 결제율은 40.0%로 가장 높다.
적당히 탐색한 후 결제를 결정하는 효율적인 전환 패턴을 보인다.

cluster 2의 체험 대기

→ cluster1은 3,334명 중 3,280명(98.4%)이 미방문자로 구성된 군집으로,
체험 시작 기록이 없어 체험 대기 일수를 산출할 수 없다.

— 행동 패턴 분석을 통한 결제 전환율 분석

카이제곱 검정 | 최종 결론

[p-value : 0.0013]

통계적으로 유의미함

[Cramér's V : 0.039]

효과의 크기는 약함

세 군집의 결제율이 35~40% 범위로 큰 차이가 없다는 점에서,
행동 패턴 자체보다 체험의 질적 경험이나 외부 요인이 결제에 더 큰 영향을 미칠 가능성이 있다.
따라서 결제 전환을 정확히 파악하기 위해서 유저의 행동 데이터 외에 외부 요인을 함께 확인해야 한다.

— 행동 패턴 분석을 통한 결제 전환율 분석

비즈니스 액션 제안

Cluster 0 | 고관여 유저

방문 일수나 체류시간은 가장 길지만 결제율은 35.3% 수준에 머물러 있다.

체험 마지막날 또는 종료 후 24시간 이내 첫 달 할인, 입장권 1회 제공 등 소액 혜택을 제공해 결제 전환을 유도한다.

Cluster 1 | 미방문 결제 유저

결제율은 36.2%이지만 체험 이용 지표가 거의 0에 가깝다.

이용 기록이 없는 유저들의 이탈을 방지하기 위해, 최초 방문을 유도하는 지점 이용 가이드나 방문 리마인드 알림을 제공한다.

Cluster 2 | 목적 지향형 결제 유저


신청 후 체험 시작까지 대기 기간(1.41일)이 길지만, 결제 전환율(40.0%)은 가장 높다.

신청 후 대기 기간 동안 이용 가이드, 이용 후기 등 추가 콘텐츠를 발송해 첫 방문 동기를 높인다.

시공간 요인 분석 및 최종 결제 예측 모델

시공간 요인 통계 검정

□ 2022년 vs 2023년 평균 결제 전환율 비교




22년 VS. 23년 전환율

카이제곱 검정 결과:

p-value = 0.00000561

연도별 전환율 편차가 매우 유의미하다.

□ 2022년 vs 2023년 가입 월별 평균 결제 전환율 트렌드 비교



월별 가입자 기준 결제 패턴


카이제곱 검정 결과:

p-value = 0.000838

무료체험 유저의 결제 행동 기전에 특정 분기 및 시즌별 '계절성 지수(Seasonality)'가

강력하게 작용하고 있음을 뜻한다.

시공간 요인 통계 검정




지점 크기 그룹별 체류시간 ANOVA 검정		
대형 지점	F	PR(>F)
소형 지점	1487.499266	3.190980e-292
잔차	NaN	NaN

지점 크기별 총 체류시간 ANOVA

대형 지점은 풍부한 공간 인프라를 바탕으로 유저의 락인(Lock-in) 효과(체류시간 증대)를 견인하고 있으며,
이것이 곧 높은 결제 전환율로 연결되는 핵심 행동 기전이다.

시공간 요인 통계 검정

□ 지점 크기별 실제 결제 전환율 비교 (기준: 100.0평)




지점\결제 여부	결제 X	결제 O
대형 지점	62.785934	37.214066
소형 지점	66.228332	33.771668
카이제곱 통계량: 7.9455 P-value: 0.00482068		

지점 크기별 결제 전환율 카이제곱 검정

대형 지점 이용 유저의 전환율(37.21%)이 소형 지점 이용 유저(33.77%)를 유의미하게 압도하며,
대형 공간 경험이 유료 결제 유도에 긍정적 효과를 유발함을 입증했다.

요일별 결제 전환율 분석



가입 요일 (Weekday)	미결제율 (%)	결제 전환율 (%)
월요일	63.67%	36.33%
화요일	65.80%	34.20%
수요일	62.12%	37.88%
목요일	62.67%	37.33%
금요일	65.60%	34.40%
토요일	71.98%	28.02%
일요일	67.63%	32.37%

요일별 결제 전환율 카이제곱 검정

요일 간 카이제곱 통계량: 16.3891 | P-value: 0.01181108


유저의 가입 요일에 따른 유료 전환율의 편차가 유의수준 5% 하에서 통계적으로 유의미하다.

시간대 그룹 정의 테이블


그룹	시간대 세그먼트	구획 기준 (Hour)
1	오전	05시 ~ 11시
2	점심 / 오후	11시 ~ 16시
3	저녁 / 야간	16시 ~ 21시
4	심야 / 새벽	21시 ~ 05시

요일 × 시간대 결합 히트맵 분석

□ [실제 방문자] 요일 × 시간대별 유입 규모 (유저 수)



□ [실제 방문자] 요일 × 시간대별 결제 전환율 (%) 트렌드



시공간 특성 반영과 변수 정제를 통한 최종 결제 예측 모델링


변수명	변수 설명	
visit_days	총 방문 일수	3일간의 무료체험 기간 중 지점을 방문한 횟수
avg_stay_sec	평균 체류 시간	1회 방문 시 지점에 머문 평균 시간
days_to_first_visit	첫 방문 소요 일수	무료체험 신청 후 실제 첫 입실까지 걸린 시간
first_site_area	첫 방문 지점 면적	유저가 처음 경험한 지점의 평수
time_group_오전 / time_group_저녁_야간 / time_group_심야_새벽	최초 입실 시간대 그룹화 변수	다중공선성 우회를 위해 유입량이 가장 많은 낮 시간대(점심_오후)를 비교 기준으로 설정

최종 생성 변수 기준 다중공선성(VIF) 검정 결과표

변수명	다중공선성 지수 (VIF)	통계적 판정 (Status)
avg_stay_sec	1.2313	● 양호 (VIF < 5)
time_group_저녁_야간	1.1597	● 양호 (VIF < 5)
time_group_오전	1.1422	● 양호 (VIF < 5)
visit_days	1.1302	● 양호 (VIF < 5)
days_to_first_visit	1.0776	● 양호 (VIF < 5)
first_site_area	1.0053	● 양호 (VIF < 5)

로지스틱 회귀 - AUC 0.6332

ROC-AUC **0.6332**




지표	미결제	결제	전체
Precision	0.72	0.47	—
Recall	0.57	0.63	—
F1-score	0.64	0.53	—
Accuracy	—	—	0.59
ROC-AUC	—	—	0.6332

- 기존 모델링의 최대 약점이었던 최초 입실 시간의 공선성 노이즈(VIF 11.21)를 시간대 그룹화 함수를 통해 효과적으로 해소했다.
- 재측정 결과 모든 변수의 VIF가 1.23 이하로 수렴하며 통계적 견고함을 확보했다.
- 로지스틱 모델의 판별력이 0.6332로 최고점을 갱신했다.

방문 시간대 별 고객 유형

방문 시간 대 별 고객 유형 사용 변수 : 입실 시각, 퇴실 시각, 주말 여부(0: 평일, 1: 주말)




ELBOW METHOD

그래프가 완만해지는 5를 k값으로 설정하여
클러스터링 진행

방문 시간대 별 고객 유형

사용 변수 : 입실 시각, 퇴실 시각, 주말 여부




cluster	0	1	2	3	4
enter_hour	16.16	1.71	13.87	0.14	11.13
leave_hour	21.04	4.7	19.03	21.57	16.66
is_weekend	0.00	0.23	1.00	0.31	0.00

• 0 그룹 (평일저녁)

- 평일 방문
- 16시 입실
- 21시 퇴실
- 퇴근 시간 때 방문하여 밤까지 있는 그룹

방문 시간대 별 고객 유형

사용 변수 : 입실 시각, 퇴실 시각, 주말 여부




cluster	0	1	2	3	4
enter_hour	16.16	1.71	13.87	0.14	11.13
leave_hour	21.04	4.7	19.03	21.57	16.66
is_weekend	0.00	0.23	1.00	0.31	0.00

• 1 그룹(새벽)

- 1시 입실
- 4시 퇴실
- 주말에도 이런 패턴이 있다.

방문 시간대 별 고객 유형

사용 변수 : 입실 시각, 퇴실 시각, 주말 여부




cluster	0	1	2	3	4
enter_hour	16.16	1.71	13.87	0.14	11.13
leave_hour	21.04	4.7	19.03	21.57	16.66
is_weekend	0.00	0.23	1.00	0.31	0.00

- 2 그룹(주말오후)

- 주말 방문
- 14시 입실
- 19시 퇴실
- 주말 오후에 방문하여 쏟아붓는 그룹

방문 시간대 별 고객 유형

사용 변수 : 입실 시각, 퇴실 시각, 주말 여부




cluster	0	1	2	3	4
enter_hour	16.16	1.71	13.87	0.14	11.13
leave_hour	21.04	4.7	19.03	21.57	16.66
is_weekend	0.00	0.23	1.00	0.31	0.00

• 3 그룹(하루종일)

- 0시 입실
- 22시 퇴실
- 하루종일 공유오피스에 체류하는 그룹
- 주말에도 이런 패턴이 있다.

방문 시간대 별 고객 유형



사용 변수 : 입실 시각, 퇴실 시각, 주말 여부



cluster	0	1	2	3	4
enter_hour	16.16	1.71	13.87	0.14	11.13
leave_hour	21.04	4.7	19.03	21.57	16.66
is_weekend	0.00	0.23	1.00	0.31	0.00

- 4 그룹(평일점심)
 - 평일 방문
 - 11시 입실
 - 16시 퇴실
 - 가장 스탠다드한 타입 그룹


방문 시간대 별 고객 유형 3 그룹 이상치 발견



원 : 3그룹의 퇴실 시각, 오 : 23시에 퇴실하는 고객들은 몇분에 퇴실하는 지

- 23시에 대부분의 방문자들의 퇴실시간이 몰려있다.
- 분으로 확인하니까 59분에 퇴실 데이터가 몰려있다.
- 59분까지 퇴실을 찍지않는 방문자들을 퇴실로 보는 데이터로 판단
- 3그룹 고객들은 퇴실을 찍지 않아서 강제 퇴실된 고객들로 간주하고 일단 3그룹은 제거 후 분석

방문 시간대 별 고객 유형 방문 시간대 유형 별 특징




방문 시간대 유형 별 규모

가장 규모가 큰 그룹은 4그룹(평일점심)이다.
다음으로는 0그룹(평일저녁)이 높다.

이를 통해 주말보다는 평일에 방문객 수가 많다는 것을 알 수 있다.


방문 시간대 별 고객 유형 방문 시간대 유형 별 특징



방문 시간대 유형 별 결제전환율

결제전환율이 제일 높은 그룹은 0그룹(평일저녁)이다.
다음으로 높은 그룹은 1그룹(새벽)이다.
하지만 2그룹(주말오후)은 결제전환율이 37.7 %로 그룹 중
에 제일 낮다.

방문 시간대 별 고객 유형 방문 시간대 유형 별 특징




방문 시간대 유형 별 첫 방문까지 걸린 일수

0번 그룹(평일저녁)과 4번 그룹(평일점심)이 신청 후 가장 빨리 오피스를 방문하였다.
주말만 오는 그룹은 평일 그룹보다 미세하게 방문이 있었다.
새벽반은 2일 이상으로 가장 길다.

방문 시간대 별 고객 유형

방문 시간대 유형 별 특징



방문 시간대 유형 별 출석 유지율

가장 유지율이 높은 그룹은 1그룹(새벽)이 높다. 규모는 작지만 방문 추이와 결제율이 공유오피스의 만족도를 나타낸다.

반대로 유지율이 가장 낮은 그룹은 4그룹(평일점심)이다. 규모가 가장 큰 그룹이지만 하루만 경험해보고 이탈하는 허수 고객이다.

방문 시간대 별 고객 유형 비즈니스 액션

0 그룹(평일저녁)

- 규모도 2위고 결제율도 1위인 그룹
- 이 그룹의 이탈을 막기 위해서는 지금 정책은 그대로 유지하면서 1일차 퇴실 시점에 '하루 더 방문하면 첫 결제 만원 할인'같은 알리를 보내기

1 그룹(새벽)

- 2일차 유지율이 높고 최종 결제율도 2위로 높다.
- 새벽 시간대의 공간 만족도가 실제 재방문으로 이어진다는 것을 확인. 심야 보안 강화하여 이 점을 마케팅한다.

2 그룹(주말오후)

- 결제전환율 최하위 그룹
- 주말 전용 요금제를 만들어 결제 진입 장벽을 낮춰야 한다.

4 그룹(평일점심)

- 가장 규모가 크지만 2일차 유지율이 뚝 떨어진다.
- 유지율을 높이기 위해 3일 동안 사물함을 무료 체험할 수 있게 하여 짐은 두고 가게 유도한다.

[p-value : 0.0017]

통계적으로 유의미하다.

마케팅 전략 제안

분석 결과 기반 비즈니스 액션 방향

“결제 전환은 단순히 체류 시간이나 방문 횟수 하나로 설명되지 않는다
고객을 단일 기준으로 나누기보다, 신청 → 방문 → 반복 방문 → 결제 여부의 흐름에 따라 유형화하고 단계별 액션을 제안한다



분석 결과 요약

- 01 체류시간이 길다고 결제율이 무조건 높지 않다
- 02 방문일수에 따라 전환 가능성 차이 발생
- 03 반복 방문했지만 결제하지 않는 고객 존재
- 04 미방문 고객과 방문 고객의 문제 원인이 다르다




비즈니스 액션 방향

- 01 단순 이용량 기준 타케팅 지양
- 02 방문 단계별 고객군 분리
- 03 이용패턴 기반 요금제 추천
- 04 메세지 목적 분리



고객 행동 단계에 따른 고객군 재정의



고객군 재 정의 기준

구분	역할
클러스터링	고객의 이용 패턴을 파악하기 위한 분석 기준
최종 고객군	메시지·혜택·예산을 집행하기 위한 실행 기준

고객 행동 단계에 따른 고객군 재정의

고객 전환 흐름 기준



고객군	기준	인원	목적
A. 신청 후 미방문+미결제형	신청 O, 방문 X, 결제 X	2,164명	첫 방문 유도
B. 1회 방문 미결제형	1일 방문, 결제 X	1,880명	2일차 재방문 유도
C. 반복 방문 미결제형	2~3일 방문, 결제 X	1,561명	이용패턴 기반 결제 전환 유도
D. 최종 미전환 고객군	캠페인 후에도 결제 X	사후 확정	피드백 수집 및 서비스 개선

고객군별 이탈 원인 가설



문제 상황

A

01

신청은 했지만 방문하지 않음



B

02

한 번 방문 후 재방문 없음



C

03

여러 번 방문 했지만 결제하지 않음



D

04

캠페인 후에도 결제하지 않음



원인 가설

01

위치, 일정, 지점 정보 부족 가능성

02

이용 루틴 형성 실패

03

적합한 요금제 연결 부족

04

가격, 시설, 위치 등 결제 장벽 존재

일괄 발송의 비효율성

고객군별로 결제하지 않은 이유가 명확히 다르기 때문에, 동일한 쿠폰이나 메시지를 일괄 발송하는 방식은 마케팅리소스 방비를 초래한다

비즈니스 액션 비용 산정 기준

※ 알림톡, 메시지, 쿠폰 및 리워드 등 비즈니스 액션별 단가와 사용 목적을 정리한 비용 산정 기준표이다

항목	단가	사용목적
정보성 알림톡	13원/ 건	위치 안내, 지점 안내, 요금제 추천, 피드백 폼 발송
광고/혜택성 메시지	20원/ 건	방문 유도, 쿠폰 안내, 혜택성 메시지
재방문 쿠폰	3,000원/ 사용자	1회 방문 고객의 2일차 재방문 유도
직접 다운로드 쿠폰	3,000원/ 사용자	반복 방문 고객의 결제 전환 유도
피드백 리워드	1,000원/ 응답자	미방문 · 미결제 사유 수집

고객 유형별 마케팅 전략 제안

A. 신청 후 미방문+미결제형

Target Audience

대상 고객

2,164명

무료체험을 신청 후
미방문+미결제 고객

Primary Objective

주요 목적

첫 방문 유도

공간 경험을 최우선으로 하여
심리적 장벽 제거

Action

실행방안

- 지점/위치 안내 알림톡
- 방문 유도 혜택성 메시지
- 맞춤 안내 제공

제외 방안

- 결제 광고 X
- 멤버십 할인권 X
- 강한 쿠폰 X

기대 효과 및 개선 방향

- **비용 효율화:** 미방문 전체 3,415명
→ 미방문·미결제 2,164명으로 타겟 축소

- **전환 목표 조정:** 결제 유도보다 첫 방문 안내를
우선

- **브랜드 신뢰:** 방문 전 과도한 할인 대신 필요한
정보 제공한다

B. 1회 방문 미결제형

Target Audience

대상 고객

1,880명

한 번 방문 후
미재방문 + 미결제 고객

Primary Objective

주요 목적

2일차 재방문 유도

한 번 방문만으로는
이용 루틴이 형성되지 않았기 때문에
결제보다 재방문 경험 확대

Action

실행방안

- 2일차 재방문 유도 메시지
- 다른 지점 이용 가능 안내
- 소액 재방문 쿠폰 제공

제외 방안

- 바로 월권 결제 유도 X
- 강한 결제 할인 X
- 미방문자 대상 쿠폰 X

기대 효과 및 개선 방향

- **재방문 유도:** 1회 방문 후 끊긴 고객에게 2일차 방문 계기 제공한다

- **비용 효율화:** 1회 방문 미결제자만 대상으로 재방문 쿠폰 운영한다

- **루틴 형성:** 연동앱으로 하루 체험에서 끝나지 않도록 반복 이용 경험 확대한다

C. 반복 방문 미결제형

[WEB]

최근 저녁 시간대 이용이 많으셨어요.
같은 패턴이라면 평일 저녁권으로 알뜰하게 이용해보세요



Target Audience

대상 고객

1,561명

무료체험 기간 동안
2~3일 반복 방문했지만
결제하지 않은 고객

Primary Objective

주요 목적

이용패턴 기반 결제 전환

개인 패턴에 맞는 요금제 안내로
관심과 이용니즈를 극대화

Action

실행방안

- 이용 시간대 기반 요금제 추천
- 저녁권·시간권·주말권 안내
- 직접 다운로드 쿠폰 제공

제외 방안

- 할인쿠폰 일괄 푸시 X
- 강한 할인 남발 X
- 동일 메시지 일괄 발송 X

기대 효과 및 개선 방향

- **전환 정교화:** 반복 방문 고객에게 이용패턴 기반 상품 추천한다
- **비용 효율화:** 쿠폰 일괄 지급이 아닌 직접 다운로드 방식으로 할인비 통제한다
- **개인화 강화:** 이용 시간대·방문 패턴에 맞는 메시지로 결제 설득력 강화한다

D. 최종 미전환향

Target Audience

대상 고객

사후 확정

캠페인 진행 후에도
결제로 이어지지 않은
최종 미전환 고객

Primary Objective

주요 목적

결제 장벽 파악

추가 할인으로 전환을 압박하기보다
미방문·미결제 사유를 수집하여
서비스 개선

Action

실행방안

- 미방문 사유 피드백 폼 발송
- 방문 후 미결제 사유 조사
- 요금제·지점·메시지 개선에 반영

제외 방안

- 반복 광고 발송 X
- 추가 할인 남발 X
- 동일 설문 일괄 발송 X

기대 효과 및 개선 방향

- **원인 파악:** 미방문 고객과 방문 미결제 고객의 이탈 사유를 분리 수집한다

- **서비스 개선:** 가격·위치·시설·요금제 등 결제 장벽 확인한다

- **향후 캠페인 고도화:** 피드백 기반으로 메시지와 상품 개선한다

유형별 실행 항목 및 비용

A. 신청 후 미방문·미결제형

세부 항목	계산식	책정 비용
지점/위치 안내 알림톡	2,164명 × 13원	28,132원
방문 유도 혜택성 메시지	2,164명 × 20원	43,280원
결제 할인 쿠폰	0원	0원
소계		71,412원

A유형은 아직 공간 경험이 없는 고객이므로 결제 쿠폰 비용은 제외하고, 위치 안내와 방문 유도 메시지 비용만 반영한다

B. 1회 방문 미결제형

세부 항목	쿠폰 사용률 10%		쿠폰 사용률 20%	
	계산식	책정 비용	계산식	책정 비용
재방문 유도 메시지	1,880명 × 20원	37,600원	1,880명 × 20원	37,600원
다른 지점 이용 안내	1,880명 × 13원	24,440원	1,880명 × 13원	24,440원
2일차 재방문 쿠폰	1,880명 × 10% × 3,000원	564,000원	1,880명 × 20% × 3,000원	1,128,000원
소계(10%)		626,040원	소계(20%)	1,190,040원

B유형은 쿠폰 사용률에 따라 비용 차이가 크게 발생함
 기본안은 10% 사용률 기준 626,040원, 보수안은 20% 사용률 기준 1,190,040원으로 산정한다

C. 반복 방문 미결제형

세부 항목	다운로드 쿠폰 사용률 5%		다운로드 쿠폰 사용률 10%	
	계산식	책정 비용	계산식	책정 비용
이용패턴 기반 추천 알림톡	1,561명 × 13원	20,293원	1,561명 × 13원	20,293원
시간 요금제 추천 알림톡	1,561명 × 13원	20,293원	1,561명 × 13원	20,293원
직접 다운로드 쿠폰 안내	1,561명 × 20원	31,220원	1,561명 × 20원	31,220원
직접 다운로드 쿠폰 사용 비용	1,561명 × 5% × 3,000원	234,150원	1,561명 × 10% × 3,000원	468,300원
소계(5%)		305,956원	소계(10%)	540,106원

C유형은 직접 다운로드 쿠폰 방식으로 실제 관심 고객에게만 할인 비용이 발생하도록 설계함
 기본안은 5% 사용률 기준 305,956원, 보수안은 10% 사용률 기준 540,106원

D. 최종 미전환 고객군

구분	인원
미방문·미결제 고객	2,164명
방문 미결제 고객	1회 방문 미결제 1,880명 + 반복 방문 미결제 1,561명 = 3,441명
전체 미결제 고객	5,605명

세부 항목	계산식	책정 비용
미방문 사유 품 발송	2,164명 × 13원	28,132원
미방문 사유 응답 리워드	2,164명 × 10% × 1,000원	216,400원
방문 미결제 피드백 품 발송	3,441명 × 13원	44,733원
방문 미결제 응답 리워드	3,441명 × 10% × 1,000원	344,100원
소계		633,365원

최종 미전환 고객군은 캠페인 이후 확정되므로, 현재 미결제 고객 5,605명을 기준으로 최대 예비비를 산정한다

전체 비용 요약

기본 실행안	
구분	비용
신청 후 미방문·미결제형	71,412원
1회 방문 미결제형	626,040원
반복 방문 미결제형	305,956원
최종 미전환 고객군 피드백	633,365원
총합	1,636,773원



- 재방문 쿠폰 사용률 10%
- 다운로드 쿠폰 사용률 5%
- 피드백 응답률 10%

보수 실행안	
구분	비용
신청 후 미방문·미결제형	71,412원
1회 방문 미결제형	1,190,040원
반복 방문 미결제형	540,106원
최종 미전환 고객군 피드백	633,365원
총합	2,434,923원



- 재방문 쿠폰 사용률 20%
- 다운로드 쿠폰 사용률 10%
- 피드백 응답률 10%

전체 고객에게 보냈을 때 vs 현재 타킷 전략

구분	전체 미결제 고객 5,605명 일괄 적용 시	현재 타킷 전략	절감액
A. 방문 유도 액션	184,965원	71,412원	113,553원
B. 2일차 재방문 유도	1,866,465원	626,040원	1,240,425원
C. 이용패턴 기반 전환 유도	1,098,580원	305,956원	792,624원
D. 피드백 수집	633,365원	633,365원	0원
합계	3,783,375원	1,636,773원	2,146,602원 절감



약 56.7% 절감

$$2,146,602\text{원} \div 3,783,375\text{원} \times 100 = \text{약 } 56.7\% \text{ 절감}$$

보수안 기준

구분	전체 미결제 고객 5,605명 일괄 적용 시	현재 타깃 전략	절감액
A. 방문 유도 액션	184,965원	71,412원	113,553원
B. 2일차 재방문 유도	3,547,965원	1,190,040원	2,357,925원
C. 이용패턴 기반 전환 유도	1,939,330원	540,106원	1,399,224원
D. 피드백 수집	633,365원	633,365원	0원
합계	6,305,625원	2,434,923원	3,870,702원 절감



약 61.4% 절감

$$3,870,702\text{원} \div 6,305,625\text{원} \times 100 = \text{약 } 61.4\% \text{ 절감}$$

비용 축소형 제안

A. 전환 중심형

실행 대상	이유	비용
신청 후 미방문·미결제형	2일차 재방문 유도	626,040원
반복 방문 미결제형	이용패턴 기반 추천	305,956원
합계		931,996원

전환 중심형은 미방문 고객을 제외하고, 실제 공간을 한 번 이상 경험한 미결제 고객에게 집중하는 방식
전환 가능성이 높은 고객군에 예산을 우선 배분한다

B. 피드백 수집형

실행 대상	이유	비용
최종 미전환 고객군 피드백	미방문 사유와 미결제 사유 수집	633,365원
합계		633,365원

피드백 수집형 = 피드백을 바탕으로 문제를 개선하는 방식
왜 방문하지 않았는지, 왜 결제하지 않았는지를 데이터를 통해 먼저 분석한 뒤, 운영의 정확도를 높인다

C. 메시지만 실행형

실행 대상	이유	비용
신청 후 미방문·미결제형 메시지	2일차 재방문 유도	71,412원
1회 방문 미결제형 메시지	이용패턴 기반 추천	62,040원
반복 방문 미결제형 메시지	이용패턴 기반 추천	71,806원
최종 미전환 고객군 폼 발송만	미방문 사유와 미결제 사유 수집	72,865원
합계		278,123원

메시지만 실행형은 쿠폰과 리워드 비용을 모두 제외하고 메시지 발송만 실행.
쿠폰이나 리워드가 없기 때문에 행동 변화나 응답률은 낮을 가능성이 높다

비즈니스 액션 최종 정리

핵심 결과

결제 전환은 단순 이용량만으로 설명되지 않으며, 방문일수·재방문 여부·이용패턴에 따라 전환 가능성이 다르게 나타난다

핵심 인사이트

고객을 단일 기준이 아닌 전환 퍼널 기준으로 구분해야 하며, 고객 행동 단계별로 다른 메시지와 혜택 설계가 필요하다

비즈니스 액션

- 미방문 고객: 첫 방문 유도
- 1회 방문 고객: 2일차 재방문 유도
- 반복 방문 고객: 이용패턴 기반 요금제 추천
- 최종 미전환 고객: 피드백 수집 및 서비스 개선

최종 제안

예산이 충분할 경우 전체 실행안을 운영하고,
예산이 제한될 경우 방문 경험이 있는 미결제 고객에게 집중하는 **전환 중심형 축소안을 우선 제안한다**

회고와 한계점

데이터의 한계

코로나 시기와 관련된 수용 인원, 위치, 공간 유형, 가격 같은 비행동적 변수가 함께 있었다면 단순 입출입 데이터만으로는 확인하기 어려운 이용 맥락까지 반영해 더 깊은 인사이트를 도출할 수 있었을 것입니다.

데이터의 행동 편중성

데이터가 행동 데이터 중심으로 구성되어 있어, 실제 결제 결정에 결정적인 영향을 미치는 가격 프로모션 등의 비행동적 요인의 영향력을 충분히 포착하지 못한 점이 아쉬움으로 남습니다.

모델 해석의 한계

ROC-AUC가 높지 않아 개별 고객의 결제 여부를 정확히 판별하는데 한계가 있었습니다. 따라서 본 모델은 정밀 예측보다 결제 가능성이 높은 고객을 우선 선별하는 보조 지표로 해석하는 것이 적절합니다.

Q&A
